PROBABILIDAD Y ESTADÍSTICA

Guía de estudio

Conceptos clave
Estadística descriptiva · Distribuciones · Correlación · Probabilidad

Material de consulta organizado para facilitar la lectura y el repaso.

Cómo usar esta guía

Avanza por los temas en orden. Identifica la definición, revisa las fórmulas y observa cómo se interpretan las medidas en un contexto de análisis de datos.

Contenido

1. Introducción
2. Medidas de tendencia central
3. Medidas de dispersión
4. Percentiles y distribución
5. Correlación
6. Probabilidad
7. Hoja de referencia: estadística descriptiva

Introducción

¿Por qué estadística y probabilidad?

Antes de calcular medidas, conviene entender qué problema resuelven. Esta lección presenta las ideas base que usarás en toda la sección.

Los datos nunca son iguales

Imagina que cada pedido de una empresa de domicilios tardara exactamente 35 minutos. No harían falta promedios, rangos ni probabilidades: bastaría con decir "35 minutos". En la realidad eso nunca pasa. En septiembre, los pedidos de Rápido, la empresa que usarás como caso en toda la sección, tardaron desde 12 hasta 72 minutos. Unos clientes viven más lejos, unos días llueve, unos repartidores conocen mejor la zona.

Esa variación es la razón de ser de la estadística y la probabilidad. La estadística te da herramientas para describir y resumir datos que varían. La probabilidad te da un lenguaje para hablar de lo que todavía no ha pasado: qué tan posible es que el próximo pedido llegue tarde.

Definiciones base

Estadística

Es la ciencia que se ocupa de la recopilación, el análisis, la interpretación y la presentación de datos.

Ejemplo: registrar el tiempo de cada pedido, calcular el promedio por sucursal y mostrarlo en un tablero para la gerencia.

Probabilidad

Es una herramienta matemática para estudiar el azar: mide qué tan posible es que ocurra un evento, con un número entre 0 (imposible) y 1 (seguro).

Ejemplo: si 29 de 240 pedidos llegaron tarde, la probabilidad estimada de que un pedido llegue tarde es 29 ÷ 240 = 0,12, es decir, 12 %.

Población, muestra, variable y dato

Estas cuatro palabras aparecen en cualquier libro de estadística. Así se ven en el caso de Rápido:

Concepto	Definición	En el caso de Rápido
Población	Todos los casos que quieres estudiar.	Todos los pedidos que Rápido ha entregado y entregará.
Muestra	Una parte de la población que observas.	Los 240 pedidos de septiembre.
Variable	Una característica que se mide en cada caso.	El tiempo de entrega, la sucursal, la calificación.
Dato	El valor que toma la variable en un caso concreto.	El pedido 1001 tardó 24 minutos y es de la sucursal Sur.

Las variables pueden ser numéricas, como el tiempo o el valor del pedido, o categóricas, como la sucursal o si llovió. El tipo de variable decide qué medidas tienen sentido: puedes promediar minutos, pero no puedes promediar sucursales.

Describir y concluir: las dos ramas

Estadística descriptiva

Organiza y resume los datos que tienes: tablas, gráficos, promedios, porcentajes. Responde qué pasó.

Ejemplo: en septiembre el tiempo promedio de entrega fue de 35,0 minutos.

Estadística inferencial

Usa la muestra para sacar conclusiones sobre toda la población y usa la probabilidad para medir qué tan confiables son esas conclusiones. Responde qué podemos esperar.

Ejemplo: con los datos de septiembre, estimar qué tan probable es que un pedido de octubre llegue tarde un día de lluvia.

Por eso van juntas: la estadística descriptiva te dice cómo se comportaron tus datos; la probabilidad conecta esos datos con decisiones sobre el futuro. Un analista de datos usa las dos todos los días, aunque no siempre las llame por su nombre. Más adelante, en machine learning, los modelos predicen precisamente con probabilidades.

Lo que vas a aprender en esta sección

Cada lección responde una pregunta de negocio distinta:

Pregunta de la gerencia de Rápido	Concepto	Lección
¿Cuánto vale un pedido típico?	Medidas de tendencia central	1
¿Qué sucursal es más confiable?	Medidas de dispersión	2
¿Qué tiempo de entrega podemos prometer?	Percentiles y distribución	3
¿Qué se relaciona con una mala calificación?	Correlación	4
¿Qué tan probable es llegar tarde si llueve?	Probabilidad	5

Términos clave 12 términosEstadísticaCiencia que se ocupa de recopilar, analizar, interpretar y presentar datos.ProbabilidadHerramienta matemática para estudiar el azar: mide qué tan posible es que ocurra un evento.PoblaciónEl conjunto completo de personas, objetos o casos que se quiere estudiar.MuestraUna parte de la población que se selecciona para estudiarla y sacar conclusiones sobre el todo.VariableUna característica que se puede medir u observar en cada miembro de la población, como el tiempo de entrega.DatoEl valor concreto que toma una variable en un caso, como 24 minutos en un pedido.Variable numéricaVariable cuyos valores son números con los que tiene sentido hacer cuentas: tiempo, valor, distancia.Variable categóricaVariable cuyos valores son grupos o etiquetas: sucursal, método de pago, si llovió o no.Estadística descriptivaLa parte de la estadística que organiza y resume los datos con tablas, gráficos y medidas.Estadística inferencialLa parte que usa los datos de una muestra para sacar conclusiones sobre la población, apoyándose en la probabilidad.ParámetroUn número que describe a toda la población, como el tiempo promedio de todos los pedidos de Rápido.EstadísticoUn número calculado con la muestra, como el promedio de los 240 pedidos de septiembre. Sirve para estimar el parámetro.

FuentesWalpole, R., Myers, R., Myers, S. y Ye, K. (2012). Probabilidad y estadística para ingeniería y ciencias (9.ª ed.). Pearson Educación.Capítulo 1: Introducción a la estadística y al análisis de datos · Libro impresoIllowsky, B. y Dean, S. (2022). Introducción a la estadística. OpenStax.Sección 1.1: Definiciones de estadística, probabilidad y términos clave · openstax.org↗

Medidas de tendencia central

Medidas de tendencia central

La media, la mediana y la moda responden la misma pregunta de formas distintas: ¿cuál es el valor típico de mis datos?

El caso de esta sección: trabajas como analista en Rápido, una empresa de domicilios con tres sucursales. Tienes los datos de 240 pedidos de septiembre: tiempo de entrega, valor del pedido, distancia, si llovió y la calificación del cliente. Lo vas a usar en todas las lecciones, en la clase y en los laboratorios.

Concepto

Las medidas de tendencia central, también llamadas medidas de ubicación, son números que resumen dónde se ubica el centro de un conjunto de datos: su valor típico o representativo. Las tres más usadas son la media, la mediana y la moda.

Tres formas de encontrar el valor típico

Media (promedio)

Definición: la suma de todos los valores dividida entre la cantidad de valores. Usa toda la información, pero los valores extremos la arrastran hacia ellos.

Ejemplo: pedidos de $20.000, $30.000 y $40.000. Suma $90.000, dividida entre 3: la media es $30.000.

Mediana

Definición: el valor que divide los datos ordenados en dos partes iguales: la mitad queda por debajo y la otra mitad por encima. Si hay una cantidad par de datos, es el promedio de los dos centrales.

Ejemplo: $20.000, $30.000, $40.000, $50.000 y $500.000. Ya están ordenados; el del medio es el tercero: la mediana es $40.000, aunque haya un pedido de $500.000.

Moda

Definición: el valor que aparece con más frecuencia. Puede haber más de una moda. Es la única de las tres que sirve para datos categóricos, como la sucursal.

Ejemplo: cinco clientes califican 4, 5, 4, 3 y 4. El 4 aparece tres veces: la moda es 4.

Pruébalo: un pedido fuera de lo común

Estos son 7 pedidos de un día. Los seis primeros son fijos; el séptimo, en magenta, lo cambias tú con los botones o con el control. Mira cómo se calcula cada medida con los valores en pantalla.

Valor del séptimo pedido:

MEDIA

MEDIANA

Lo que pasa en los datos reales de Rápido

En septiembre una empresa hizo un pedido corporativo de $2.000.000 para un evento. Mira cómo cambia la lectura del negocio según la medida que elijas:

Medida del valor del pedido	Con el pedido corporativo	Sin el pedido corporativo
Media	$55.359	$47.222
Mediana	$41.000	$40.800

Un solo pedido subió la media en más de $8.000, mientras la mediana casi no se movió. Si la gerencia planea una promoción para "el cliente promedio", la mediana describe mucho mejor a ese cliente.

¿Cuál uso?

Situación	Medida recomendada
Datos numéricos sin valores extremos, como el tiempo de entrega	Media o mediana: darán valores parecidos
Datos con valores extremos, como salarios, precios de vivienda o valor de compras	Mediana
Categorías o escalas, como sucursal, método de pago o calificación	Moda

Regla práctica: la mediana suele ser una mejor medida del centro cuando hay valores extremos, porque no depende de qué tan grandes sean. Por eso, si la media y la mediana están muy separadas, revisa tus datos. Casi siempre hay unos pocos valores muy altos o muy bajos tirando de la media.

Términos clave 8 términosTendencia centralGrupo de medidas que resumen con un solo número dónde se concentran los datos: media, mediana y moda.Valor típicoEl número que mejor representa a la mayoría de los datos. Es lo que se busca con una medida de tendencia central.Media o promedioLa suma de todos los valores dividida entre la cantidad de valores. En pandas: `mean()`.MedianaEl valor que queda en el centro cuando los datos se ordenan de menor a mayor. Si la cantidad de datos es par, es el promedio de los dos centrales. En pandas: `median()`.ModaEl valor que más se repite. Un conjunto puede tener una moda, varias o ninguna. En pandas: `mode()`.Valor extremo o atípicoUn dato mucho más alto o más bajo que el resto. En inglés se le llama outlier. Puede ser un error o un caso real poco común.Variable numéricaUna columna cuyos valores son números con los que tiene sentido hacer cuentas, como el tiempo o el valor de un pedido.Variable categóricaUna columna cuyos valores son grupos o etiquetas, como la sucursal. Para ella solo tiene sentido la moda.

FuentesWalpole, R., Myers, R., Myers, S. y Ye, K. (2012). Probabilidad y estadística para ingeniería y ciencias (9.ª ed.). Pearson Educación.Capítulo 1: Introducción a la estadística y al análisis de datos · Libro impresoIllowsky, B. y Dean, S. (2022). Introducción a la estadística. OpenStax.Sección 2.5: Medidas del centro de los datos · openstax.org↗Documentación oficial de pandasGuía de usuario: estadística descriptiva (mean, median, mode, std, quantile) · pandas.pydata.org↗

Medidas de dispersión

Medidas de dispersión

Dos grupos pueden tener el mismo promedio y comportarse muy distinto. La dispersión mide qué tan lejos del centro están los datos.

Concepto

La dispersión, también llamada variabilidad o escala, mide qué tanto se separan los datos entre sí y respecto a su centro. Las medidas de tendencia central dicen dónde está el valor típico; las de dispersión dicen qué tan lejos de ese valor suelen quedar los datos. Dos grupos con el mismo promedio pueden tener una dispersión muy distinta.

Las tres medidas

Rango

Definición: el valor más alto menos el valor más bajo.

Cómo se lee: la distancia entre los dos extremos, en las mismas unidades de los datos. Solo usa dos valores, así que un único dato extremo lo cambia todo.

Varianza

Definición: el promedio de los cuadrados de las desviaciones, donde la desviación de un dato es su diferencia con la media.

Cómo se lee: mientras más grande, más dispersos los datos. Por el cuadrado, sus unidades quedan en minutos al cuadrado, que no tienen un significado práctico. Por eso casi nunca se reporta: es el paso intermedio para llegar a la desviación estándar.

Desviación estándar

Definición: la raíz cuadrada de la varianza. Mide qué tan lejos están, en general, los datos de su media, en las mismas unidades que los datos.

Cómo se lee: cuánto se alejan en general los datos del promedio, de nuevo en las unidades originales. Una desviación de 4 minutos significa que los pedidos suelen quedar unos 4 minutos por encima o por debajo del promedio.

Paso a paso con 5 pedidos

No vas a calcular la varianza a mano en tu trabajo: pandas lo hace en una línea. Pero hacerlo una vez con pocos datos te muestra qué hay detrás del número. Estos son los tiempos de 5 pedidos:

Pedido	Tiempo	Diferencia con la media (35)	Diferencia al cuadrado
1	30 min	-5	25
2	33 min	-2	4
3	35 min	0	0
4	37 min	2	4
5	40 min	5	25
Total	175 min	0	58

1 Calcula la media: 175 entre 5 da 35 minutos.

2 Resta la media a cada dato: así sabes cuánto se aleja cada pedido. Fíjate que estas diferencias suman 0: las negativas cancelan a las positivas, por eso no sirven solas.

3 Eleva cada diferencia al cuadrado: así todas quedan positivas y no se cancelan. Suman 58.

4 Divide entre la cantidad de datos menos 1: 58 entre 4 da una varianza de 14,5 minutos al cuadrado. Se divide entre n menos 1 porque tus datos son una muestra: así la varianza de la muestra estima mejor la de toda la población. Pandas lo hace así por defecto.

5 Saca la raíz cuadrada: la raíz de 14,5 da una desviación estándar de 3,8 minutos, otra vez en minutos.

El rango de estos pedidos es 40 menos 30: 10 minutos.

Cómo leer el resultado

El número solo cobra sentido cuando lo comparas. Estos dos procesos tienen el mismo promedio de 35 minutos:

Proceso A: 30, 33, 35, 37 y 40 min

Desviación estándar de 3,8 min. Los pedidos suelen llegar entre 31 y 39 minutos. Un cliente puede confiar en el tiempo que le prometen.

Proceso B: 20, 25, 35, 45 y 50 min

Desviación estándar de 12,7 min. Los pedidos suelen llegar entre 22 y 48 minutos. El promedio es el mismo, pero nadie sabe cuándo va a llegar su pedido.

Regla de lectura: promedio más o menos una desviación estándar te da el intervalo donde cae la mayoría de los datos. Mientras más pequeña la desviación, más estrecho el intervalo y más predecible el proceso. Si la desviación es cero, todos los datos son iguales.

Una advertencia: como la varianza y la desviación estándar elevan las diferencias al cuadrado, los valores extremos pesan mucho en ellas. Si tus datos tienen extremos, compleméntalas con el rango intercuartílico, que verás en la siguiente lección y no se deja afectar por las colas.

En los datos de Rápido

Las sucursales Norte y Sur tardan casi lo mismo en promedio. Si solo miraras la media, dirías que funcionan igual:

Sucursal	Tiempo promedio	Rango	Desviación estándar	Pedidos de más de 45 min
Norte	35,2 min	30 min	6,6 min	5,1 %
Sur	35,1 min	60 min	12,6 min	21,2 %

La desviación de Norte es 6,6 minutos: la mayoría de sus pedidos llega entre 29 y 42 minutos. En Sur es 12,6 minutos, así que el intervalo va de 22 a 48 minutos. Por eso en Sur uno de cada cinco pedidos llega tarde, aunque el promedio sea el mismo.

Pruébalo: aumenta la dispersión

Los 20 pedidos de abajo tienen siempre un promedio de 35 minutos. Mueve el control para alejarlos o acercarlos al centro y observa cómo cambian la desviación, el rango y los pedidos tarde.

Dispersión

Términos clave 7 términosDispersiónQué tanto se separan los datos entre sí y respecto a su centro. Poca dispersión significa datos parecidos; mucha dispersión, datos muy distintos.RangoEl valor

máximo menos el valor mínimo. Mide la distancia entre los dos extremos.Diferencia respecto a la mediaLo que se aleja cada dato del promedio: el dato menos la media. Es positiva si el dato está por encima y negativa si está por debajo.VarianzaEl promedio de las diferencias respecto a la media elevadas al cuadrado. Sus unidades quedan al cuadrado. En pandas: `var()`.Desviación estándarLa raíz cuadrada de la varianza. Indica, en las unidades originales, cuánto se alejan en general los datos del promedio. En pandas: `std()`.MuestraUna parte de todos los casos posibles, como los pedidos de un solo mes. Por eso pandas divide entre n menos 1 al calcular la varianza.ConsistenciaEn negocio, que un proceso dé resultados parecidos cada vez. Una desviación estándar pequeña indica un proceso consistente y predecible.

FuentesWalpole, R., Myers, R., Myers, S. y Ye, K. (2012). Probabilidad y estadística para ingeniería y ciencias (9.ª ed.). Pearson Educación.Capítulo 1: Introducción a la estadística y al análisis de datos · Libro impresoIllowsky, B. y Dean, S. (2022). Introducción a la estadística. OpenStax.Sección 2.7: Medidas de la dispersión de los datos · openstax.org↗Documentación oficial de pandasSeries.std · pandas.pydata.org↗

Percentiles y distribución

Percentiles, cuartiles y forma de los datos

Los percentiles responden preguntas como "¿qué tiempo de entrega podemos prometer?". La forma de la distribución te dice qué tan confiables son el promedio y la mediana.

¿Qué es un percentil?

Concepto

Los percentiles dividen los datos ordenados en centésimas. Un percentil es el valor que deja por debajo un porcentaje determinado de los datos, una vez ordenados de menor a mayor: el percentil 90 deja por debajo, o igual, al 90 % de los datos y por encima al 10 % restante.

Imagina los 240 pedidos de septiembre en una fila, del más rápido al más lento. Si caminas por la fila hasta dejar atrás al 90 % de ellos, el tiempo del pedido donde te detienes es el percentil 90: 46 minutos. En palabras de negocio: 9 de cada 10 pedidos llegan en 46 minutos o menos. Por eso los percentiles se usan para fijar promesas al cliente y metas de servicio.

Cómo los cuartiles dividen los datos

Los cuartiles dividen los datos ordenados en cuartos: son tres percentiles especiales que parten los datos en cuatro grupos con la misma cantidad de datos. El primer cuartil (Q1) es el percentil 25, la mediana (Q2) es el percentil 50 y el tercer cuartil (Q3) es el percentil 75. Mira cómo funciona con 20 pedidos ordenados por tiempo de entrega:

1. Ordena los tiempos de menor a mayor.
2. Parte la fila en cuatro grupos iguales. Con 20 pedidos, cada grupo tiene 5: el 25 % de los datos.
3. Las fronteras entre grupos son los cuartiles. Q1 = 29 minutos: el 25 % de los pedidos tarda eso o menos. Q2 = 35 minutos es la mediana: la mitad tarda eso o menos. Q3 = 41 minutos: el 75 % tarda eso o menos.
4. Entre Q1 y Q3 está la mitad central de los pedidos, de 29 a 41 minutos. Su ancho, 41 menos 29 = 12 minutos, es el rango intercuartílico.

Fíjate: los grupos tienen la misma cantidad de pedidos, no el mismo ancho en minutos. El último grupo va de 41 a 60 minutos porque los pedidos lentos están más separados entre sí. Que un grupo sea ancho te dice que en esa zona los datos están dispersos.

Pruébalo con los 240 pedidos

Mueve el control para elegir un percentil. Las barras azules son los pedidos que quedan por debajo de él.

Percentil

Los cuartiles en describe()

En los 240 pedidos reales pasa lo mismo que en el ejemplo de 20. Con `describe()`, pandas te entrega los tres cuartiles junto a las demás medidas en una sola tabla:

Fila	tiempo_min	Qué significa
count	240.0	Cuántos pedidos hay
mean	35.0	Tiempo promedio

Fila	tiempo_min	Qué significa
std	9.4	Desviación estándar
min	12.0	El pedido más rápido
25%	29.0	Primer cuartil (Q1): el 25 % de pedidos tarda esto o menos
50%	35.0	Mediana (Q2): la mitad de los pedidos tarda esto o menos
75%	41.0	Tercer cuartil (Q3): el 75 % tarda esto o menos
max	72.0	El pedido más demorado

Entre el Q1 y el Q3 está la mitad central de los pedidos: de 29 a 41 minutos. Esa distancia, 12 minutos, se llama rango intercuartílico: indica la dispersión de la mitad central de los datos. Es la caja que verás en los diagramas de caja de la clase de visualización.

Regla para detectar valores atípicos

Un valor se considera un posible atípico si queda más de 1,5 rangos intercuartílicos por debajo de Q1 o por encima de Q3. En Rápido: el rango intercuartílico es 12, así que 1,5 × 12 = 18. El límite superior es 41 + 18 = 59 minutos y el inferior, 29 menos 18 = 11 minutos. Solo 2 pedidos, de 67 y 72 minutos, quedan por fuera: son los que vale la pena revisar uno por uno.

La forma de una distribución

Cuando agrupas los datos en un histograma, aparece una forma. Las dos más comunes en negocio son estas:

Simétrica: tiempo de entrega

Los datos se agrupan en el centro y bajan parecido hacia ambos lados. La media (35,0) y la mediana (35) casi coinciden.

Sesgada a la derecha: valor del pedido

La mayoría de pedidos son de valor bajo y unos pocos son muy altos, formando una cola larga. La media queda por encima de la mediana.

La distribución normal

Muchos fenómenos se parecen a una campana simétrica, llamada distribución normal. En ella se cumple una regla útil: cerca del 68 % de los datos queda a una desviación estándar del promedio y cerca del 95 % a dos desviaciones. No necesitas memorizar fórmulas: basta con reconocer la campana y saber que en ella la media es un buen resumen.

Términos clave 9 términosPercentilEl valor que deja por debajo un porcentaje determinado de los datos ordenados. El percentil 90 deja por debajo al 90 % de los datos.CuartilesLos tres valores que parten los datos ordenados en cuatro grupos con la misma cantidad de datos: Q1 (percentil 25), Q2 (percentil 50, la mediana) y Q3 (percentil 75).Rango intercuartílico (IQR)Q3 menos Q1. Mide qué tan ancha es la mitad central de los datos y no lo afectan los valores extremos.DistribuciónLa forma en que se reparten los valores de una variable: dónde se concentran, hacia dónde se estiran y qué tan dispersos están.HistogramaGráfico de barras que agrupa los valores en intervalos y muestra cuántos datos caen en cada uno. Permite ver la forma de la distribución.Distribución simétricaAquella en la que los datos se reparten parecido a ambos lados del centro. La media y la mediana quedan cerca.Sesgo o asimetríaCuando la distribución tiene una cola más larga hacia un lado. Con cola a la derecha, la media queda por encima de la mediana.Distribución normalDistribución simétrica con forma de campana. Cerca del 68 % de los datos queda a una

desviación estándar del promedio.`quantile()`Función de pandas que calcula percentiles. Recibe un valor entre 0 y 1: `quantile(0.9)` es el percentil 90.

FuentesWalpole, R., Myers, R., Myers, S. y Ye, K. (2012). Probabilidad y estadística para ingeniería y ciencias (9.ª ed.). Pearson Educación.Capítulo 1: Introducción a la estadística y al análisis de datos · Libro impresoIllowsky, B. y Dean, S. (2022). Introducción a la estadística. OpenStax.Sección 2.3: Medidas de la ubicación de los datos · openstax.org↗Documentación oficial de pandasSeries.quantile · pandas.pydata.org↗Documentación oficial de pandasDataFrame.describe · pandas.pydata.org↗

Correlación

Correlación

La correlación mide si dos variables numéricas se mueven juntas. Es una de las primeras preguntas que te haces al explorar un conjunto de datos, y una de las más fáciles de malinterpretar.

Concepto

La correlación mide la fuerza y la dirección de la relación lineal entre dos variables numéricas. Se resume con el coeficiente de correlación de Pearson, que se escribe r y siempre está entre -1 y 1: no puede ser mayor que 1 ni menor que -1. Mientras más cerca de 1 o de -1, más fuerte la relación lineal.

Cómo leer el coeficiente

El coeficiente tiene dos partes que se leen por separado: el signo dice la dirección y el tamaño dice la fuerza.

Positiva: r cerca de 1

Cuando una variable sube, la otra también tiende a subir.

Ejemplo: las horas que un estudiante dedica a estudiar y la nota que obtiene. Más horas suelen ir con mejores notas.

Negativa: r cerca de -1

Cuando una variable sube, la otra tiende a bajar.

Ejemplo: el precio de un producto y las unidades vendidas. Si el precio sube, normalmente se venden menos unidades.

Sin relación lineal: r cerca de 0

Las dos variables no se mueven juntas en línea recta.

Ejemplo: la talla de zapatos de un estudiante y su nota en un examen. Saber una no te dice nada de la otra.

Valor de r, sin importar el signo	Lectura habitual
Menos de 0,3	Relación débil o inexistente
Entre 0,3 y 0,7	Relación moderada
Más de 0,7	Relación fuerte

Estos cortes son una guía práctica, no una regla fija: cada disciplina usa umbrales un poco distintos. Lo importante es mirar siempre el diagrama de dispersión junto al número.

Pruébalo con los datos de Rápido

Cada punto es un pedido. Elige una pareja de variables y mira la forma de la nube de puntos junto con su coeficiente:

Dos cuidados al interpretarla

Solo mide relaciones en línea recta

Un coeficiente cercano a 0 no significa que no haya ninguna relación: puede existir una relación curva que la correlación no detecta. Por eso se mira siempre el diagrama de dispersión.

Ejemplo: la satisfacción con la temperatura de una oficina sube hasta unos 22 °C y luego baja. La relación es clara, pero tiene forma de curva y su correlación puede salir cercana a 0.

Correlación no es causalidad

Que dos variables se muevan juntas no prueba que una cause la otra. A menudo hay una tercera variable que las mueve a ambas.

Ejemplo: en una ciudad, las ventas de helado y las de bloqueador solar suben al mismo tiempo. Ninguna causa la otra: las dos dependen del calor.

En Rápido: la distancia y la calificación tienen una correlación de -0,30. Sería fácil concluir que a los clientes lejanos no les gusta el servicio. Pero la distancia alarga el tiempo de entrega (0,52) y es el tiempo el que baja la calificación (-0,66). La causa real es la demora, no la distancia.

Términos clave 8 términosCorrelaciónMedida de qué tanto dos variables numéricas se mueven juntas en línea recta.Coeficiente de correlaciónEl número que resume la correlación. Va de -1 a 1: el signo indica la dirección y la cercanía a 1 o a -1 indica la fuerza. En pandas: `corr()`.Correlación positivaCuando una variable sube, la otra tiende a subir. Ejemplo: distancia y tiempo de entrega.Correlación negativaCuando una variable sube, la otra tiende a bajar. Ejemplo: tiempo de entrega y calificación.Diagrama de dispersiónGráfico de puntos en el que cada punto es un caso, ubicado según el valor de dos variables. Sirve para ver una correlación.CausalidadRelación en la que un cambio en una variable produce el cambio en la otra. Una correlación por sí sola no la demuestra.Tercera variableUn factor que mueve a dos variables al mismo tiempo y hace que parezcan relacionadas entre sí. También se le llama variable de confusión.Relación linealRelación en la que los puntos de un diagrama de dispersión se acercan a una línea recta. Es el único tipo de relación que mide el coeficiente de correlación.

FuentesWalpole, R., Myers, R., Myers, S. y Ye, K. (2012). Probabilidad y estadística para ingeniería y ciencias (9.ª ed.). Pearson Educación.Capítulo 11: Regresión lineal simple y correlación · Libro impresoIllowsky, B. y Dean, S. (2022). Introducción a la estadística. OpenStax.Capítulo 12: Regresión lineal y correlación, términos clave · openstax.org↗Documentación oficial de pandasDataFrame.corr · pandas.pydata.org↗

Probabilidad

Probabilidad básica

La probabilidad es el lenguaje para hablar de lo que todavía no ha pasado. En analítica la usas para estimar riesgos, comparar grupos y, más adelante, para entender cómo predicen los modelos de machine learning.

El vocabulario de la probabilidad

Todos los libros de probabilidad empiezan con las mismas cuatro ideas. Para entenderlas, usa el ejemplo más simple posible: lanzar un dado de seis caras.

Concepto	Definición	Con un dado	En Rápido
Experimento aleatorio	Una acción cuyo resultado no se conoce antes de hacerla.	Lanzar el dado.	Entregar un pedido.
Resultado	Lo que produce el experimento una vez.	Sale un 4.	El pedido tardó 38 minutos.
Espacio muestral (S)	El conjunto de todos los resultados posibles.	S = {1, 2, 3, 4, 5, 6}	Todos los tiempos posibles de entrega.
Evento	Cualquier combinación de resultados que te interesa.	A = sale par = {2, 4, 6}	T = el pedido llega tarde (más de 45 minutos).

¿Qué es una probabilidad?

Concepto

La probabilidad de un evento es un número entre 0 y 1 que mide qué tan posible es que ocurra: 0 significa que es imposible y 1 que es seguro. Se interpreta como la frecuencia relativa con la que ocurre el evento si el experimento se repite muchas veces.

Hay dos formas de calcularla:

Cuando todos los resultados son igualmente probables

Divides los resultados favorables entre los resultados posibles.

Ejemplo: P(sale par) = 3 ÷ 6 = 0,5, porque hay 3 caras pares entre 6 caras.

Cuando tienes datos: la frecuencia relativa

Cuentas cuántas veces ocurrió el evento y lo divides entre el total de casos. Es la forma que usarás en analítica.

Ejemplo: 29 de los 240 pedidos llegaron tarde: P(tarde) ≈ 29 ÷ 240 = 0,12, es decir, 12,1 %.

Pruébalo: la ley de los grandes números

Si lanzas una moneda, la probabilidad de cara es 0,5. Pero en 10 lanzamientos puede salir cara 7 veces. La ley de los grandes números dice que, al repetir el experimento muchas veces, la frecuencia relativa se acerca cada vez más a la probabilidad teórica. Lanza la moneda y compruébalo:

Toca un botón para lanzar la moneda.

Esto tiene una consecuencia práctica: una probabilidad estimada con pocos datos es poco confiable. Con 240 pedidos tu estimación es razonable; con 10 pedidos podría estar muy lejos de la realidad.

Tres reglas básicas

1. El complemento

El complemento de A, que se escribe A′, son todos los resultados que no están en A. Como A y A′ cubren todo el espacio muestral, P(A) + P(A′) = 1.

Dado: P(no sale 6) = 1 menos 1/6 = 5/6.
Rápido: P(llega a tiempo) = 1 menos 0,12 = 0,88.

2. El evento A y B

Son los resultados que cumplen las dos condiciones al mismo tiempo.

Dado: A = par = {2, 4, 6} y B = mayor que 3 = {4, 5, 6}. A y B = {4, 6}, así que P(A y B) = 2/6.

3. El evento A o B

Son los resultados que cumplen al menos una de las dos condiciones. Se calcula sumando y restando lo que se contó dos veces: P(A o B) = P(A) + P(B) menos P(A y B).

Dado: A o B = {2, 4, 5, 6}. Con la regla: 3/6 + 3/6 menos 2/6 = 4/6.

Probabilidad condicional

Concepto

La probabilidad condicional de A dado B, que se escribe P(A | B), es la probabilidad de que ocurra A sabiendo que B ya ocurrió. Se calcula como P(A | B) = P(A y B) ÷ P(B), siempre que P(B) sea mayor que cero. La idea clave: un condicional reduce el espacio muestral, porque solo miras los casos en que ocurrió B.

Con un dado

Alguien lanza un dado y te dice que salió par. ¿Cuál es la probabilidad de que sea un 6?

Ya no hay 6 resultados posibles, solo 3: {2, 4, 6}. Uno de ellos es el 6, así que P(6 | par) = 1/3. Con la fórmula: (1/6) ÷ (3/6) = 1/3. Saber que salió par subió la probabilidad de 1/6 a 1/3.

Eventos independientes

Si saber que ocurrió B no cambia la probabilidad de A, los eventos son independientes: P(A | B) = P(A).

Ejemplo: lanzas una moneda dos veces. Que la primera saliera cara no cambia la probabilidad de cara en la segunda: sigue siendo 0,5.

Aplicación: ¿la lluvia cambia el riesgo de llegar tarde?

Ahora el mismo razonamiento con datos reales. Toca un grupo para calcular la probabilidad de llegar tarde dentro de él:

	Llegó tarde	A tiempo	Total
Con lluvia	18	46	64
Sin lluvia	11	165	176
Total	29	211	240

1. Con la fórmula: P(tarde y lluvia) = 18 ÷ 240 y P(lluvia) = 64 ÷ 240. Al dividirlas, el 240 se cancela: P(tarde | lluvia) = 18 ÷ 64 = 28,1 %.
2. Comparación: sin lluvia es 6,2 %. Como P(tarde | lluvia) es muy distinta de P(tarde) = 12,1 %, llegar tarde y llover no son independientes.

3 Decisión de negocio: la lluvia multiplica por más de cuatro el riesgo de llegar tarde. Rápido puede reforzar repartidores los días de lluvia o ampliar el tiempo prometido.

En pandas: filtras el grupo y sacas el promedio de la condición. Funciona porque True cuenta como 1 y False como 0, así que el promedio es la proporción.

Términos clave 12 términosExperimento aleatorioUna acción que se puede repetir y cuyo resultado no se conoce con certeza antes de hacerla, como lanzar un dado o entregar un pedido.ResultadoLo que produce un experimento en una realización concreta: sacar un 4, o que el pedido tarde 38 minutos.Espacio muestral (S)El conjunto de todos los resultados posibles. Al lanzar un dado: S = {1, 2, 3, 4, 5, 6}.EventoCualquier combinación de resultados. Se nombra con letras mayúsculas: A = sale un número par = {2, 4, 6}.ProbabilidadUn número entre 0 y 1 que mide qué tan posible es un evento. Se interpreta como la frecuencia relativa con que ocurre a largo plazo.Frecuencia relativaLas veces que ocurrió un evento divididas entre el total de repeticiones. Es la forma de estimar probabilidades con datos.Ley de los grandes númerosAl repetir un experimento muchas veces, la frecuencia relativa observada se acerca cada vez más a la probabilidad teórica.Complemento (A′)Todos los resultados que no están en A. Se cumple P(A) + P(A′) = 1.Evento A y BLos resultados que están en A y en B al mismo tiempo. También se llama intersección.Evento A o BLos resultados que están en A, en B o en ambos. También se llama unión.Probabilidad condicionalLa probabilidad de A sabiendo que ya ocurrió B. Se escribe P(A | B) y se calcula como P(A y B) ÷ P(B).Eventos independientesDos eventos son independientes si saber que ocurrió uno no cambia la probabilidad del otro: P(A | B) = P(A).

FuentesWalpole, R., Myers, R., Myers, S. y Ye, K. (2012). Probabilidad y estadística para ingeniería y ciencias (9.ª ed.). Pearson Educación.Capítulo 2: Probabilidad · Libro impresoIllowsky, B. y Dean, S. (2022). Introducción a la estadística. OpenStax.Sección 3.1: Terminología de probabilidad · openstax.org↗Illowsky, B. y Dean, S. (2022). Introducción a la estadística. OpenStax.Sección 3.2: Eventos mutuamente excluyentes e independientes · openstax.org↗Documentación oficial de pandasGuía de usuario: estadística descriptiva (mean, median, mode, std, quantile) · pandas.pydata.org↗

Hoja de referencia: estadística descriptiva

Hoja de referencia: estadística descriptiva

Las medidas y sus comandos en pandas en una sola página, para consultar mientras practicas.

Todos los ejemplos usan el DataFrame `df` de pedidos de Rápido.

Tendencia central

"valor_pedido"

"valor_pedido"

"calificacion"

0

Media, mediana y moda. Con valores extremos, prefiere la mediana.

Dispersión

"tiempo_min"

"tiempo_min"

"tiempo_min"

"tiempo_min"

Desviación estándar, varianza y rango.

Percentiles y cuartiles

"tiempo_min"

0.9

"tiempo_min"

0.25

0.5

0.75

`quantile` recibe un valor entre 0 y 1: 0.9 es el percentil 90.

Resumen completo

"tiempo_min"

Conteo, media, desviación, mínimo, cuartiles y máximo en una tabla.

Por grupo

"sucursal"

"tiempo_min"

"mean"

"median"

"std"

Las mismas medidas, calculadas para cada grupo.

Correlación

"distancia_km"

"tiempo_min"

True

De -1 a 1. Recuerda: correlación no es causalidad.

Probabilidad por frecuencia

"tiempo_min"

45

"calificacion"

True

La proporción de casos en que algo ocurrió.

Probabilidad condicional

"lluvia"

"Sí"

"tiempo_min"

45

Filtra primero el grupo y luego calcula la proporción dentro de él.

¿Qué medida uso?

Quiero saber...	Usa
El valor típico de datos sin extremos	Media
El valor típico de datos con extremos (precios, salarios, compras)	Mediana
La categoría más frecuente	Moda
Qué tan predecible o consistente es un proceso	Desviación estándar
Una meta o promesa que se cumpla casi siempre	Percentil 90 o 95
Si dos variables numéricas se mueven juntas	Correlación
Qué tan frecuente es un evento	Proporción con .mean() sobre una condición

Glosario 26 términosTendencia centralGrupo de medidas que resumen con un solo número dónde se concentran los datos: media, mediana y moda.Media o promedioLa suma de todos los valores dividida entre la cantidad de valores. En pandas: `mean()`.MedianaEl valor que queda en el centro cuando los datos se ordenan de menor a mayor. Si la cantidad de datos es par, es el promedio de los dos centrales. En pandas: `median()`.ModaEl valor que más se repite. Un conjunto puede tener una moda, varias o ninguna. En pandas: `mode()`.Valor extremo o atípicoUn dato mucho más alto o más bajo que el resto. En inglés se le llama outlier. Puede ser un error o un caso real poco común.DispersiónQué tanto se separan los datos entre sí y respecto a su centro. Poca dispersión significa datos parecidos; mucha dispersión, datos muy distintos.RangoEl valor máximo menos el valor mínimo. Mide la distancia entre los dos extremos.Diferencia respecto a la mediaLo que se aleja cada dato del promedio: el dato menos la media. Es positiva si el dato está por encima y negativa si está por debajo.VarianzaEl promedio de las diferencias respecto a la media elevadas al cuadrado. Sus unidades quedan al cuadrado. En pandas: `var()`.Desviación estándarLa raíz cuadrada de la

varianza. Indica, en las unidades originales, cuánto se alejan en general los datos del promedio. En pandas: `std()`.PercentilEl valor que deja por debajo un porcentaje determinado de los datos ordenados. El percentil 90 deja por debajo al 90 % de los datos.CuartilesLos tres valores que parten los datos ordenados en cuatro grupos con la misma cantidad de datos: Q1 (percentil 25), Q2 (percentil 50, la mediana) y Q3 (percentil 75).Rango intercuartílico (IQR)Q3 menos Q1. Mide qué tan ancha es la mitad central de los datos y no lo afectan los valores extremos.DistribuciónLa forma en que se reparten los valores de una variable: dónde se concentran, hacia dónde se estiran y qué tan dispersos están.HistogramaGráfico de barras que agrupa los valores en intervalos y muestra cuántos datos caen en cada uno. Permite ver la forma de la distribución.Distribución simétricaAquella en la que los datos se reparten parecido a ambos lados del centro. La media y la mediana quedan cerca.Sesgo o asimetríaCuando la distribución tiene una cola más larga hacia un lado. Con cola a la derecha, la media queda por encima de la mediana.Distribución normalDistribución simétrica con forma de campana. Cerca del 68 % de los datos queda a una desviación estándar del promedio.CorrelaciónMedida de qué tanto dos variables numéricas se mueven juntas en línea recta.Coeficiente de correlaciónEl número que resume la correlación. Va de -1 a 1: el signo indica la dirección y la cercanía a 1 o a -1 indica la fuerza. En pandas: `corr()`.Correlación positivaCuando una variable sube, la otra tiende a subir. Ejemplo: distancia y tiempo de entrega.Correlación negativaCuando una variable sube, la otra tiende a bajar. Ejemplo: tiempo de entrega y calificación.CausalidadRelación en la que un cambio en una variable produce el cambio en la otra. Una correlación por sí sola no la demuestra.Tercera variableUn factor que mueve a dos variables al mismo tiempo y hace que parezcan relacionadas entre sí. También se le llama variable de confusión.ProbabilidadQué tan frecuente es un evento. Se estima dividiendo los casos en que ocurrió entre el total de casos. Va de 0 a 1, o de 0 % a 100 %.Probabilidad condicionalLa probabilidad de un evento dentro de un grupo que cumple otra condición. Se escribe P(A | B) y se lee probabilidad de A dado B.

FuentesWalpole, R., Myers, R., Myers, S. y Ye, K. (2012). Probabilidad y estadística para ingeniería y ciencias (9.ª ed.). Pearson Educación.Capítulo 1: Introducción a la estadística y al análisis de datos · Libro impresoWalpole, R., Myers, R., Myers, S. y Ye, K. (2012). Probabilidad y estadística para ingeniería y ciencias (9.ª ed.). Pearson Educación.Capítulo 2: Probabilidad · Libro impresoWalpole, R., Myers, R., Myers, S. y Ye, K. (2012). Probabilidad y estadística para ingeniería y ciencias (9.ª ed.). Pearson Educación.Capítulo 11: Regresión lineal simple y correlación · Libro impresoDocumentación oficial de pandasGuía de usuario: estadística descriptiva (mean, median, mode, std, quantile) · pandas.pydata.org↗